

Guión de Presentación – Health Security Assistance

Diapositiva 1: Título – Health Security Assistance

Buenos días/tardes a todos. Hoy os presento nuestro proyecto 'Health Security Assistance', enfocado en la predicción del riesgo de diabetes mediante modelos de inteligencia artificial aplicados a datos reales de pacientes.

La idea nace de una necesidad clara: anticiparnos a enfermedades crónicas como la diabetes, que tienen un fuerte impacto tanto a nivel individual como en el sistema de salud.

Este enfoque se alinea con una visión moderna de la medicina: proactiva, personalizada y basada en datos.

Para ello desarrollaremos un modelo predictivo basado en los datos de los pacientes actuales para identificar nuevos clientes potenciales con riesgo alto de diabetes

Diapositiva 2: Contexto.

Disponemos de datos clínicos y demográficos reales que permiten anticipar conocimientos de salud y consumo.

Buscamos convertir estos datos en conocimiento accionable para marketing, ventas y desarrollo de servicios.

La diabetes representa una oportunidad estratégica para la compañía por su alta prevalencia y cronicidad

Diapositiva 3: Enfoque estratégico y resultados

Nuestro enfoque será que a partir de estos datos generar un modelo de Machine Learning y una red neuronal para predecir la probabilidad de tener diabetes.

Después aplicaremos los modelos en los datos más recientes de clientes para validar la efectividad de los modelos.

Optimización del **gasto comercial y publicitario**

Desarrollo de **productos personalizados o preventivos**

Refuerzo del **posicionamiento de la compañía**

Diapositiva 4: EDA

Trabajamos con una base de datos sólida, longitudinal y representativa.

Datos de entrenamiento: 1999 a 2017 → 15.488 clientes.

Datos para predicción: 2017 a 2023 → 6.258 clientes.

Incluyen variables clínicas (glucosa, presión arterial, IMC...) y demográficas (edad, sexo, raza...).

Esta separación temporal permite simular un caso real de predicción futura basada en experiencia pasada.

Diapositiva 5: EDA

El target como podéis observar es una variable categórica binaria, que se encuentra desbalanceada debido a que como es lógico hay más personas sin la enfermedad que con ella. Este desbalanceo va a ser clave en el desarrollo de los modelos de machine learning y de la red neuronal.

Diapositiva 6: EDA

La distribución de las variables numéricas. Comentar las variables y que se ha aplicado la transformación logarítmica en todas ellas consiguiendo una muy buena distribución normal.

Diapositiva 7: EDA

En donde se ve más cambios entre grupos es en la glicohemoglobina y el BMI y colesterol

Diapositiva 8: EDA-Matrix correlation

En la matriz de correlación podemos observar como las variables que tienen más correlación con el target son la edad, la glicohemoglobina, presión arterial y las variables que proceden del feature engineering.

Diapositiva 9: Modelos de machine learning

Ya que la variable de target esta desbalanceada utilizaremos las siguientes métricas de evaluación: Métricas de evaluación: Recall, F1-Score, Average Precision.

Probamos distintos algoritmos clásicos de ML para evaluar su rendimiento.

Los que consiguieron mejor rendimiento entre toda las métricas: Gradient Boosting, CatBoost, LightGBM.

Diapositiva 10: Evaluación de hiperparametros

Evaluamos los hiperparámetros de los 3 modelos mediante randomsearch y con el que conseguimos mejores resultados fue LightGBM sobre todo por conseguir un recall de 0.72 en la clase más desbalanceada.

Diapositiva 11: Evaluación frente a test

- El modelo alcanza una accuracy del 89%, lo que indica que casi 9 de cada 10 predicciones fueron correctas.
- La precisión es del 68%, lo que significa que de todos los casos que el modelo predijo como positivos, el 68% realmente lo eran.
- La sensibilidad o recall es del 72%, es decir, identificó correctamente al 72% de los pacientes positivos del conjunto de test.
- El F1-score, que equilibra precisión y sensibilidad, fue de 0.69.
- Finalmente, el AUC-ROC es de 0.90, lo que demuestra que el modelo tiene una excelente capacidad de distinguir entre pacientes positivos y negativos.

la curva se mantiene por encima de la diagonal y su área bajo la curva es **0.91**, lo cual confirma que el modelo tiene un comportamiento sólido, incluso en situaciones donde los umbrales

- En azul oscuro, vemos que 2427 pacientes negativos fueron correctamente clasificados como tales.
- En azul claro, 327 pacientes positivos también fueron correctamente identificados.
- El modelo comete algunos errores:
 - 202 falsos positivos, es decir, casos predichos como positivos que no lo eran.
 - Y 126 falsos negativos, que son positivos que el modelo no detectó.

En conjunto, este modelo demuestra un rendimiento robusto y equilibrado. Es capaz de detectar bien a los pacientes en riesgo de diabetes, sin generar un exceso de falsas alarmas, lo cual es clave para la toma de decisiones clínicas o comerciales

Diapositiva 12: Red neuronal profunda

Se realizó un ajuste de pesos de clase para abordar el desbalance:

- Clase 1 (diabéticos): aumento de peso en 1,2 veces.

- Clase 0 (no diabéticos): reducción de peso en 0,9 veces.

Desarrollamos una red neuronal densa, con una arquitectura específica para el problema.

Capas densas de 128, 64 y 32 unidades con activación ReLU.

Batch normalization y Dropout (0.4 y 0.3) para regularización.

Capa de salida con activación sigmoide.

Entrenamiento: Adam optimizer, binary_crossentropy, métricas: accuracy, AUC, recall, precision.

Early stopping monitorizando val_auc, con patience de 10.

Validation split: 20%, Epochs: 100, Batch size: 32.

Diapositiva 13: Evaluación frente a test (NN)

- El modelo alcanza una accuracy del 81%, algo menor que el modelo de ML, pero aún respetable.
- La precisión general para la clase positiva (es decir, pacientes diabéticos) es del 43%, lo que implica un mayor número de falsos positivos.
- Pero su recall o sensibilidad es mucho más alto: 84%, lo que significa que identifica la gran mayoría de los casos positivos reales.
- El F1-score para la clase 1 es 0.56, lo que refleja un compromiso entre la sensibilidad alta y la precisión baja.
- Además, tiene un AUC de 0.90 y un average precision de 0.72, lo cual demuestra que el modelo tiene una buena capacidad de discriminación en general.”

Como en el caso anterior, la curva se mantiene muy por encima de la diagonal aleatoria, indicando una buena capacidad para diferenciar entre clases.

- Verdaderos **negativos (TN)**: 1963 pacientes fueron correctamente clasificados como no diabéticos.
- Verdaderos **positivos (TP)**: 393 pacientes diabéticos fueron correctamente identificados.
- Falsos **positivos (FP)**: 666 personas sin diabetes fueron incorrectamente clasificadas como positivas.
- Falsos **negativos (FN)**: Solo 60 pacientes con diabetes no fueron detectados.

En resumen, la red neuronal funciona muy bien si lo que queremos es **detectar la mayoría de los casos positivos**, incluso a costa de generar más falsas alarmas. Este comportamiento puede ser deseable en contextos donde la prioridad es no dejar escapar a ningún paciente en riesgo

Diapositiva 14: Resultados ML

- Precisión para clase 1 (diabetes): 0.66 → el 66% de las predicciones positivas fueron correctas.
- Recall o sensibilidad para clase 1: 0.78 → el modelo identificó correctamente al 78% de las personas con diabetes.
- F1-score para clase 1: 0.72 → buen equilibrio entre precisión y sensibilidad.
- Precisión para clase 0 (no diabetes): 0.95, con un recall de 0.92 y F1-score de 0.93.
- La accuracy general fue del 89%, y los promedios ponderados se mantienen en torno al 0.89–0.90.
- 4718 verdaderos negativos: personas sin diabetes correctamente clasificadas.
- 861 verdaderos positivos: personas con diabetes correctamente detectadas.
- 438 falsos positivos: personas sin diabetes que el modelo clasificó como si la tuvieran.
- 241 falsos negativos: personas con diabetes que no fueron detectadas por el modelo.

Diapositiva 15: Resultados ML

- Precisión para clase 1 (diabetes): 0.41 → relativamente baja, lo que indica una mayor cantidad de falsos positivos.
- Recall o sensibilidad: 0.91 → excelente capacidad para detectar a la gran mayoría de los pacientes con diabetes.
- F1-score para clase 1: 0.56 → equilibrio moderado, reflejando la alta sensibilidad y baja precisión.
- Accuracy global: 0.75 → inferior al modelo de ML, pero aún aceptable considerando el objetivo clínico.

- El promedio ponderado de métricas se mantiene alrededor de 0.75 a 0.78, mostrando un rendimiento razonable.
- Verdaderos negativos: 3697 personas sin diabetes correctamente clasificadas.
- Verdaderos positivos: 1005 pacientes con diabetes identificados correctamente.
- Falsos positivos: 1459 personas sin diabetes clasificadas erróneamente como si la tuvieran.
- Falsos negativos: solo 97 pacientes con diabetes no fueron detectados.

Cierre y conclusiones

Este proyecto demuestra cómo los datos clínicos y la inteligencia artificial pueden convertirse en herramientas clave para la detección temprana de enfermedades crónicas.

Aporta valor en tres frentes: mejora la eficiencia comercial, aporta impacto clínico directo y refuerza el posicionamiento estratégico en salud digital.

Muchas gracias por vuestra atención. Estoy disponible para cualquier duda o comentario.